Dataset

- ชื่อชุดข้อมูล: ds_salaries.csv
- แหล่งที่มา: Kaggle: Data Science Salaries 2023

รายละเอียด:

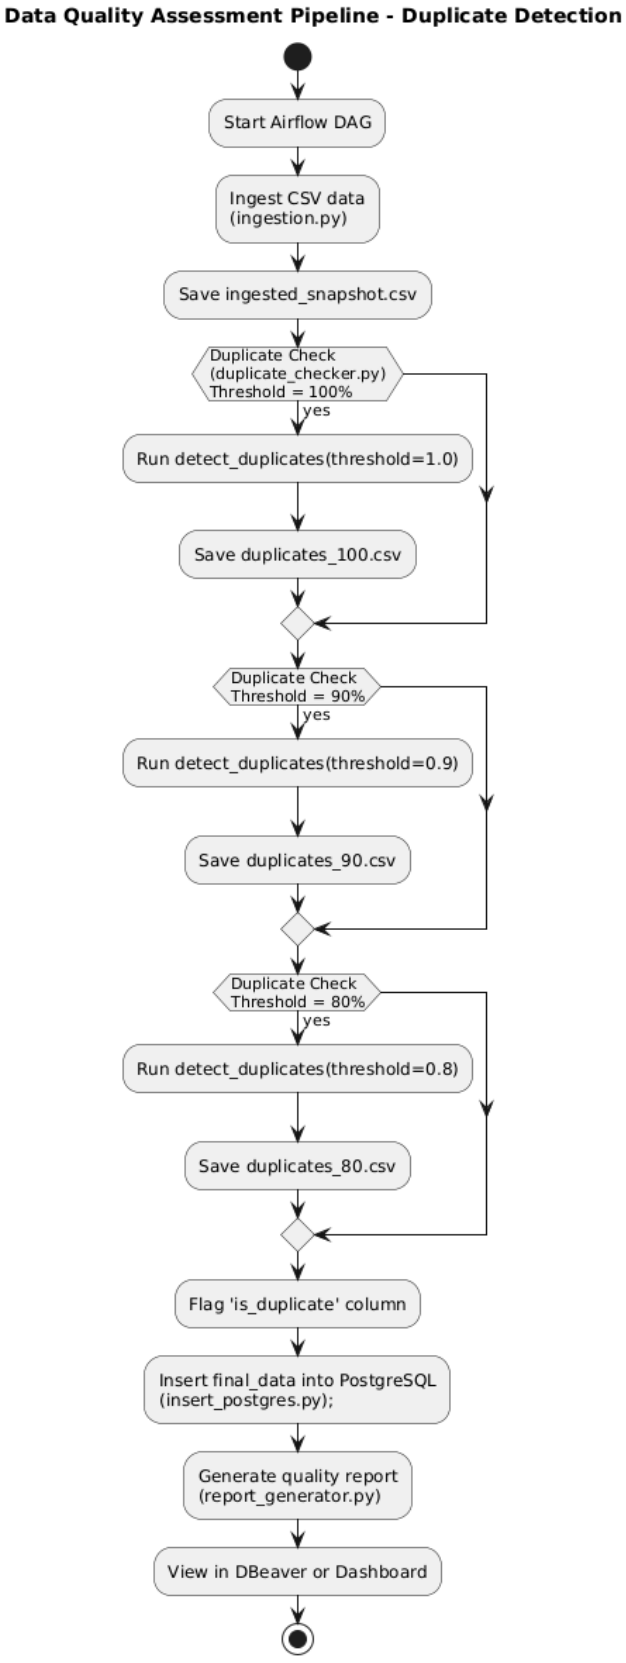
ชุดข้อมูลนี้ประกอบด้วยข้อมูลเงินเดือนของตำแหน่งงานด้าน Data Science ในช่วงปี 2020-2023 ครอบคลุมหลายประเทศ และหลากหลายระดับประสบการณ์ รูปแบบการจ้างงาน และขนาดของบริษัท โดยข้อมูลถูกจัดเก็บทั้งในรูปสกุลเงินต้นทางและถูกแปลงเป็น USD เพื่อความสะดวกในการวิเคราะห์เปรียบเทียบ

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 607 entries, 0 to 606
Data columns (total 12 columns):
 #   Column              Non-Null Count  Dtype 
---  ------              --------------  ----- 
 0   Unnamed: 0          607 non-null    int64 
 1   work_year           607 non-null    int64 
 2   experience_level    607 non-null    object
 3   employment_type     607 non-null    object
 4   job_title           607 non-null    object
 5   salary              607 non-null    int64 
 6   salary_currency     607 non-null    object
 7   salary_in_usd       607 non-null    int64 
 8   employee_residence  607 non-null    object
 9   remote_ratio        607 non-null    int64 
 10  company_location    607 non-null    object
 11  company_size        607 non-null    object
dtypes: int64(5), object(7)
memory usage: 57.0+ KB
```

ตัวอย่าง Data

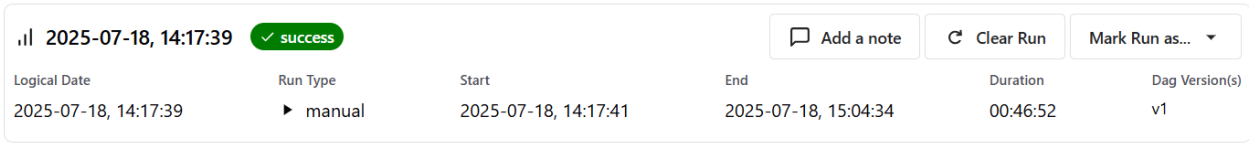
	Unnamed: 0	work_year	experience_level	employment_type	job_title	salary	salary_currency	salary_in_usd	employee_residence	remote_ratio	company_location	company_size
0	0	2020	MI	FT	Data Scientist	70000	EUR	79833	DE	0	DE	L
1	1	2020	SE	FT	Machine Learning Scientist	260000	USD	260000	JP	0	JP	S
2	2	2020	SE	FT	Big Data Engineer	85000	GBP	109024	GB	50	GB	M
3	3	2020	MI	FT	Product Data Analyst	20000	USD	20000	HN	0	HN	S
4	4	2020	SE	FT	Machine Learning Engineer	150000	USD	150000	US	50	US	L

Flow Chart


Data Quality Assessment Pipeline - Duplicate Detection
Start Airflow DAG
Ingest CSV data (ingestion.py)
Save ingested_snapshot.csv
Duplicate Check (duplicate_checker.py) Threshold = 100%
yes
Run detect_duplicates(threshold=1.0)
Save duplicates_100.csv
Duplicate Check Threshold = 90%
yes
Run detect_duplicates(threshold=0.9)
Save duplicates_90.csv
Duplicate Check Threshold = 80%
yes
Run detect_duplicates(threshold=0.8)
Save duplicates_80.csv
Flag 'is_duplicate' column
Insert final_data into PostgreSQL (insert_postgres.py);
Generate quality report (report_generator.py)
View in DBeaver or Dashboard

Part ปรับปรุง Algorithm ให้แจ๋วกว่าเดิม

ผลจากการ Run บน Airflow Old Version และ New Version



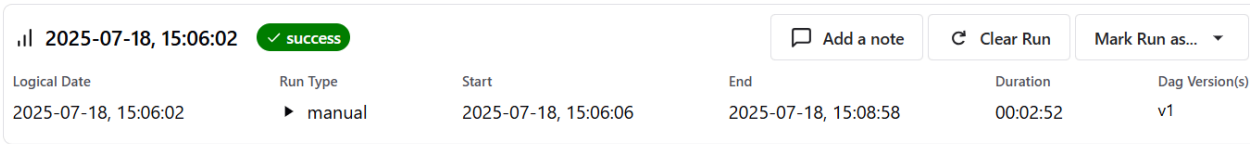
Task Instances | Events | Code | Details

Old

Search Tasks | All States

Task ID	Map Index	State	Start Date	End Date	Try Number	Operator	Duration
generate_report		success	2025-07-18, 15:04:24	2025-07-18, 15:04:34	1	PythonOperator	9.69s
detect_duplicates_80		success	2025-07-18, 14:44:46	2025-07-18, 15:04:23	1	PythonOperator	00:19:36
detect_duplicates_90		success	2025-07-18, 14:27:10	2025-07-18, 14:44:44	1	PythonOperator	00:17:33
detect_duplicates_100		success	2025-07-18, 14:17:46	2025-07-18, 14:27:10	1	PythonOperator	00:09:23
load_data		success	2025-07-18, 14:17:42	2025-07-18, 14:17:46	1	PythonOperator	4.12s

VS



Task Instances | Events | Code | Details

New

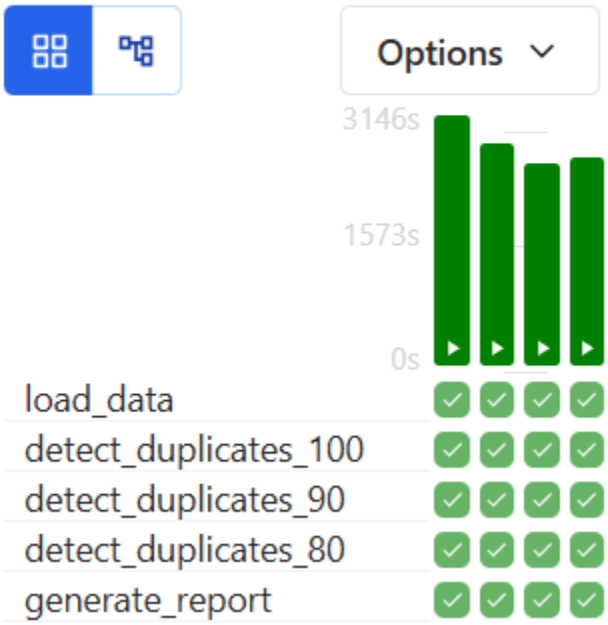
Search Tasks | All States

Task ID	Map Index	State	Start Date	End Date	Try Number	Operator	Duration
generate_report		success	2025-07-18, 15:08:49	2025-07-18, 15:08:57	1	PythonOperator	8.72s
detect_duplicates_80		success	2025-07-18, 15:07:19	2025-07-18, 15:08:47	1	PythonOperator	00:01:27
detect_duplicates_90		success	2025-07-18, 15:06:40	2025-07-18, 15:07:19	1	PythonOperator	00:00:38
detect_duplicates_100		success	2025-07-18, 15:06:22	2025-07-18, 15:06:38	1	PythonOperator	00:00:16
load_data		success	2025-07-18, 15:06:07	2025-07-18, 15:06:17	1	PythonOperator	9.92s

ผลการ Run 4 รอบ

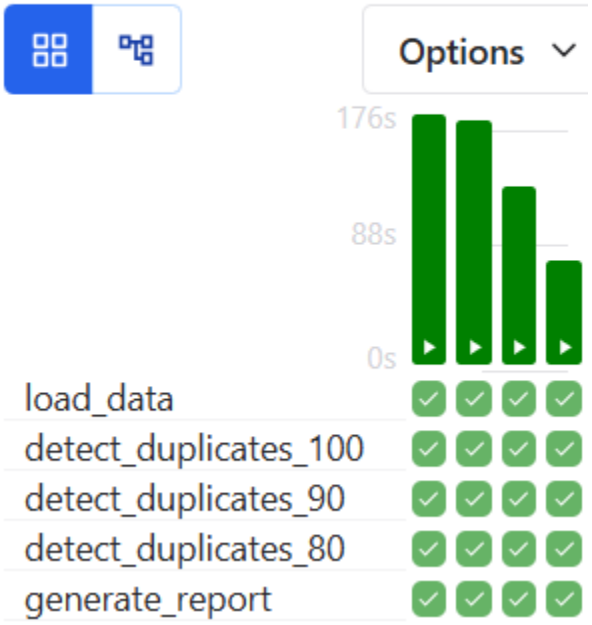
Dag

benchmark_duplicate_detection_old

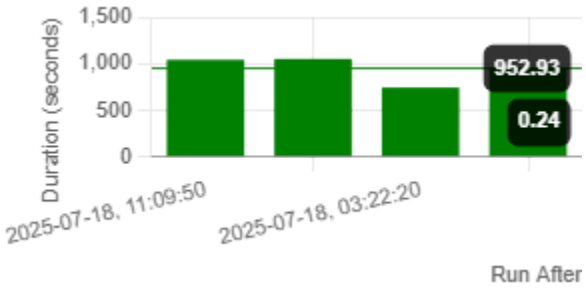


Dag

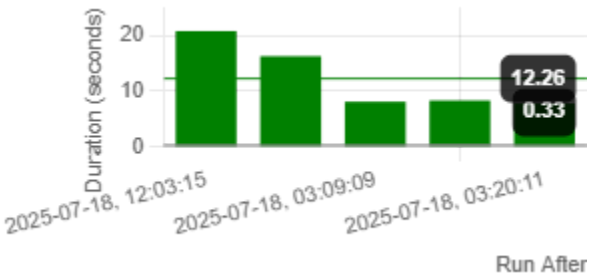
benchmark_duplicate_detection_new



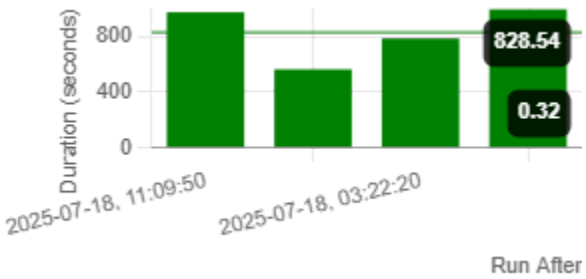
old_detect_duplicates_100



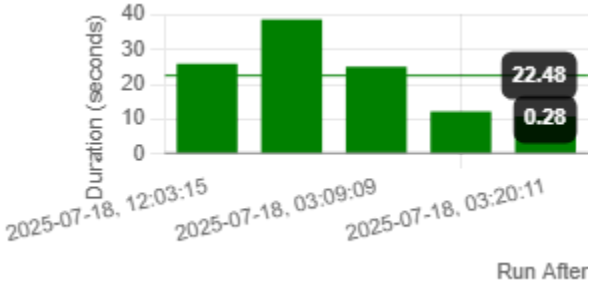
new_detect_duplicates_100



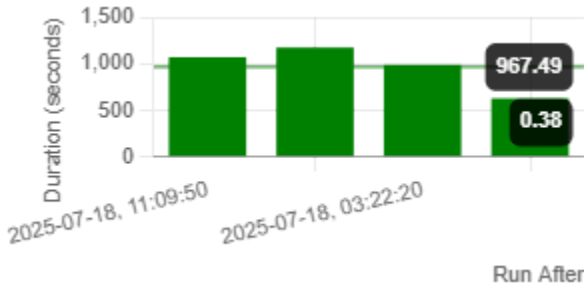
old_detect_duplicates_90



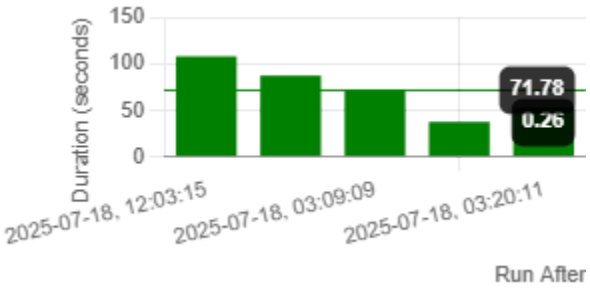
new_detect_duplicates_90



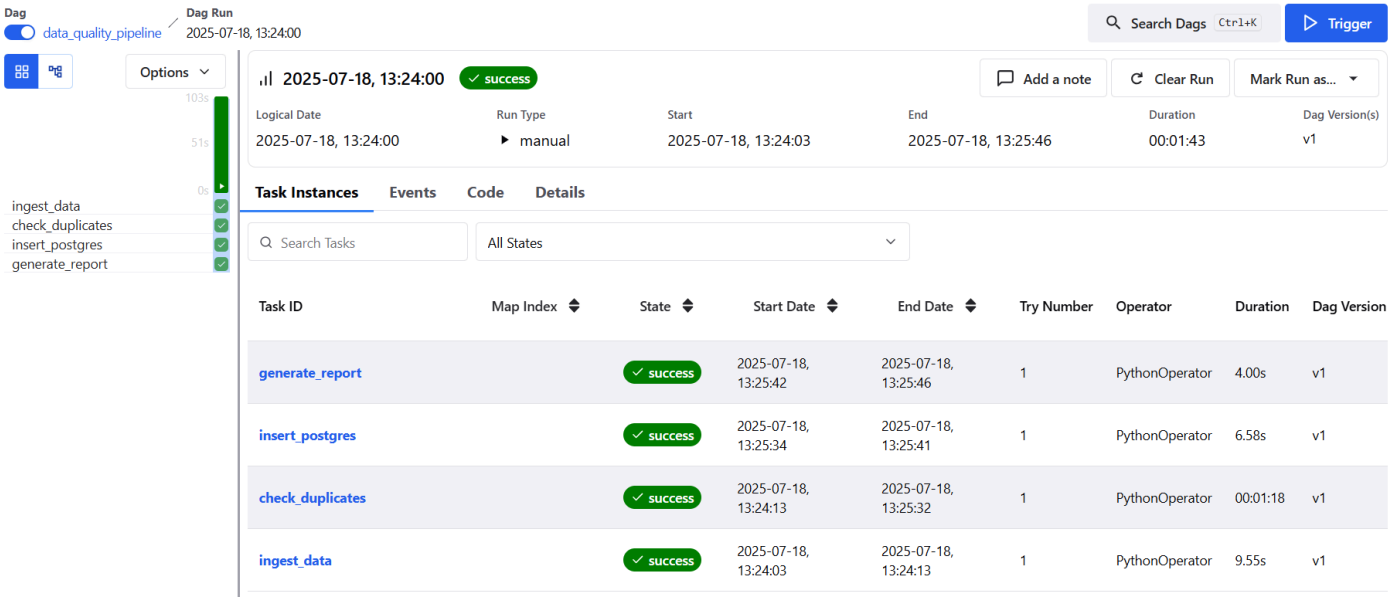
old_detect_duplicates_80



new_detect_duplicates_80



ผลการ Run ครบ Loop



จุดต่างระหว่าง Old vs New Version

เปรียบเทียบ	Old Version	New Version
โครงสร้างข้อมูล	df.iloc[i][col] == df.iloc[j][col] (Pandas)	df_values[i] == df_values[j] (NumPy array)
เปรียบเทียบ	ใช้ for loop ซ้อนกับ combinations()	ใช้ indexing บน NumPy array แบบ vectorized
ความเร็วในการรัน	ช้า เพราะ loop ทุกรายการ และเข้าถึงช้า	เร็ว เพราะ NumPy ใช้ C backend

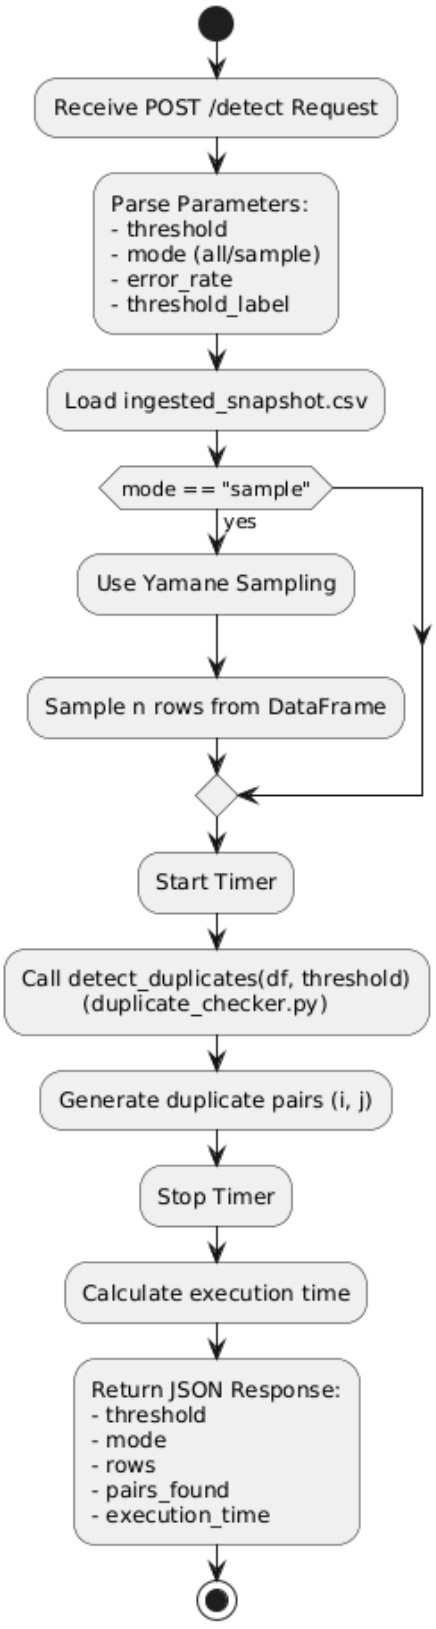
สรุป

- Old Version: ใช้ Pandas loop ⟶ ช้า เพราะทุก .iloc[i][col] มี overhead
- New Version: ใช้ NumPy vectorized operation ⟶ เร็วขึ้น เพราะไม่ต้อง loop ใน Python
- แค่เปลี่ยน df.iloc ⟶ df.values และใช้ NumPy ก็เพิ่ม performance ได้หลายสิบเท่าใน task นี้

Part Api

Using Yamane sample ในส่วน labeled_pairs

และใช้ Fast Api รัน ได้ 2 mode - all\ sample



POST `/detect` Detect

Parameters

Name	Description
threshold * required number *(query)*	Threshold (1.0, 0.9, 0.8) 1
mode string *(query)*	Detection mode sample
error_rate number *(query)*	Sampling error rate (only for sample mode) 0.05 *maximum: 0.2* *minimum: 0.01*
threshold_label integer *(query)*	Label set to compare with (100, 90, 80) 100

Response body


```
{
  "threshold": 1,
  "mode": "all",
  "rows": 607,
  "pairs_found": 67,
  "execution_time": 1.57
}
```


Response body


```
{
  "threshold": 0.9,
  "mode": "sample",
  "rows": 241,
  "pairs_found": 446,
  "execution_time": 0.29
}
```

Test new data set

- ชื่อชุดข้อมูล: players.csv
- แหล่งที่มา: Kaggle: Football Data from Transfermarkt

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 9 columns):
 #   Column             Non-Null Count  Dtype
---  ------             --------------  -----
 0   first_name         9548 non-null   object
 1   last_name          10000 non-null  object
 2   date_of_birth      9982 non-null   object
 3   country_of_birth   9281 non-null   object
 4   city_of_birth      9367 non-null   object
 5   position           10000 non-null  object
 6   foot               9300 non-null   object
 7   height_in_cm       9399 non-null   float64
 8   current_club_name  10000 non-null  object
dtypes: float64(1), object(8)
```

ผลการ run duplicate_performance.py

```
[INFO] Loaded 10000 rows with 9 columns

=== Threshold 100% ===
[INFO] Detecting duplicates with threshold: 100% → min 9/9 matches
[INFO] Duplicate pairs found: 0
[INFO] Unique duplicate rows: 0
[INFO] Execution time: 392.73 seconds
Top matched columns:

=== Threshold 90% ===
[INFO] Detecting duplicates with threshold: 90% → min 8/9 matches
[INFO] Duplicate pairs found: 0
[INFO] Unique duplicate rows: 0
[INFO] Execution time: 377.59 seconds
Top matched columns:

=== Threshold 80% ===
[INFO] Detecting duplicates with threshold: 80% → min 7/9 matches
[INFO] Duplicate pairs found: 0
[INFO] Unique duplicate rows: 0
[INFO] Execution time: 385.57 seconds
Top matched columns:

=== Summary ===
Threshold  Pairs  Rows  Time (s)
     100%     45    10    379.02
      90%     97    27    363.49
      80%    122    45    383.50
```

ผลการ Run ครบ Loop

